Création d’un algorithme de détection de faux billets

MARIE HENAULT

Contexte

- **Projet** : ONCFM – lutte contre la fraude
- **Objectif** : automatiser la détection via mesures géométriques
- **Rôle** : concevoir un algorithme fiable et fonctionnel
- **Priorité** : maximiser la détection des faux billets (recall)

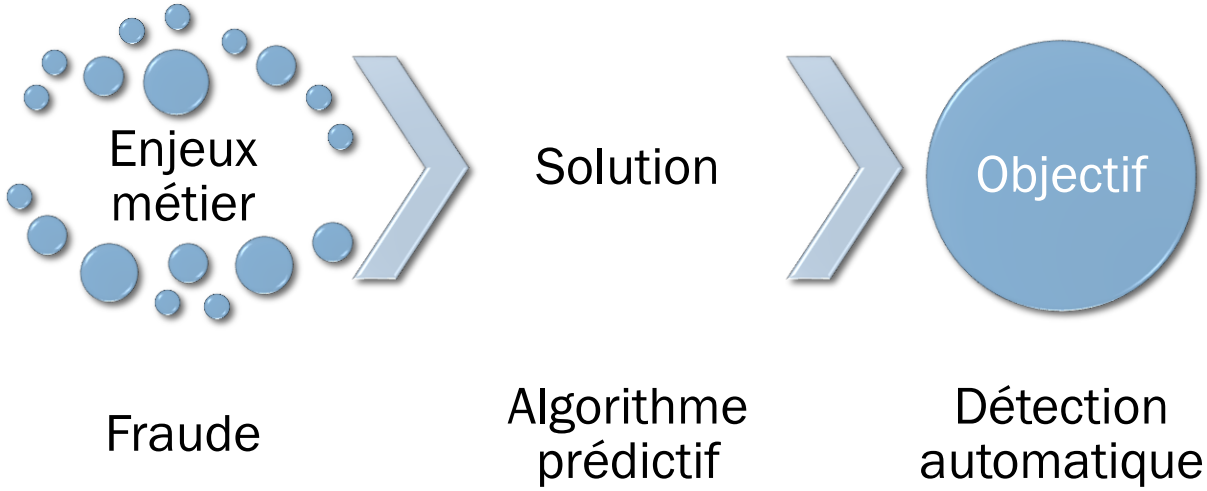

Données initiales

- **Jeu fourni** : 1500 billets (1000 vrais, 500 faux)
- **Variables** : longueur, diagonale, hauteurs, marges
- **Cible** : is_genuine (vrai/faux)
- **Particularité** : 37 valeurs manquantes (*margin_low*)
- **Production** : même format, sans la cible → prédiction par modèle

```
Dimensions du dataset : (1500, 7)

Exemple :
```

	is_genuine	diagonal	height_left	height_right	margin_low	margin_up	length
0	True	171.81	104.86	104.95	4.52	2.89	112.83
1	True	171.46	103.36	103.66	3.77	2.99	113.09
2	True	172.69	104.48	103.50	4.40	2.94	113.16
3	True	171.36	103.91	103.94	3.62	3.01	113.51
4	True	171.73	104.28	103.46	4.04	3.48	112.54

Prétraitements réalisés

- Vérification et nettoyage des données
  - Pas de doublons
  - Valeurs manquantes uniquement sur *margin_low* (37)
- Imputation : **régression linéaire** pour prédire margin_low
  - => conditions non respectées donc suppression des lignes
- Normalisation : **StandardScaler** (variables centrées-réduites)

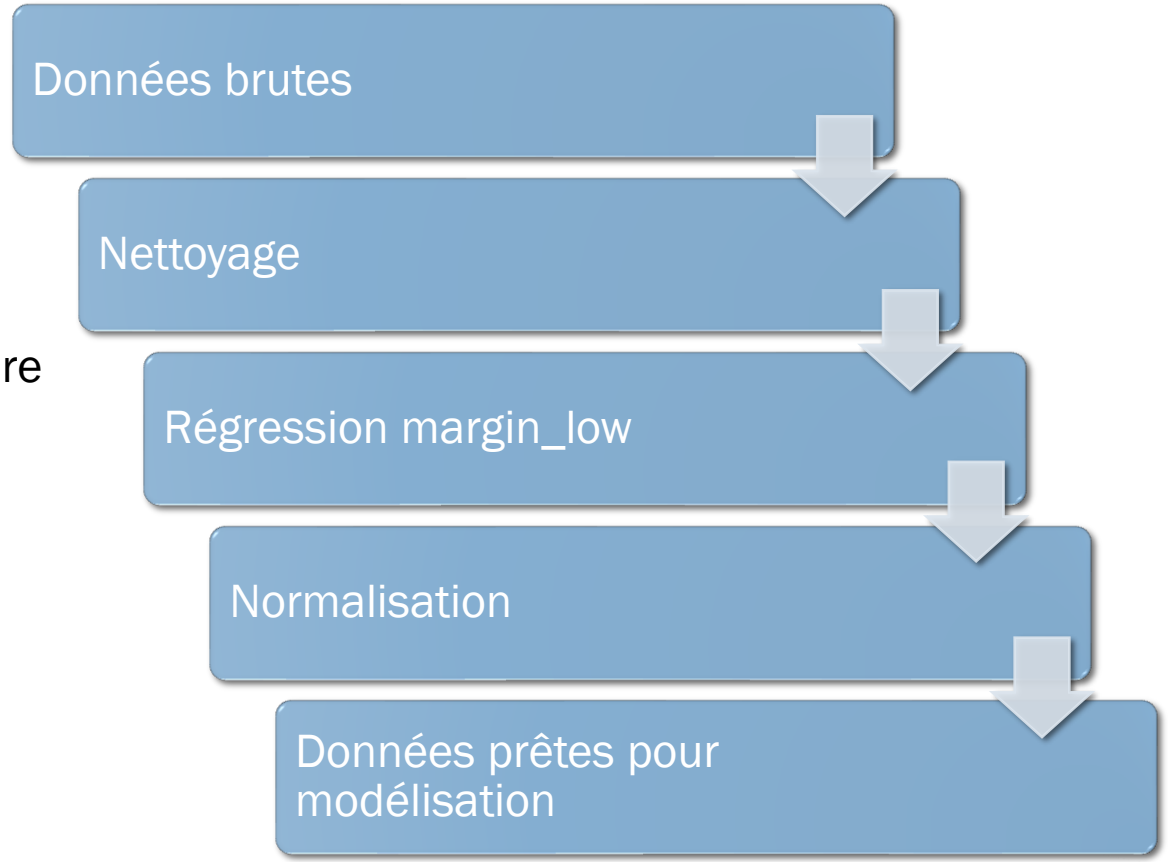

Exploration initiale 1/2

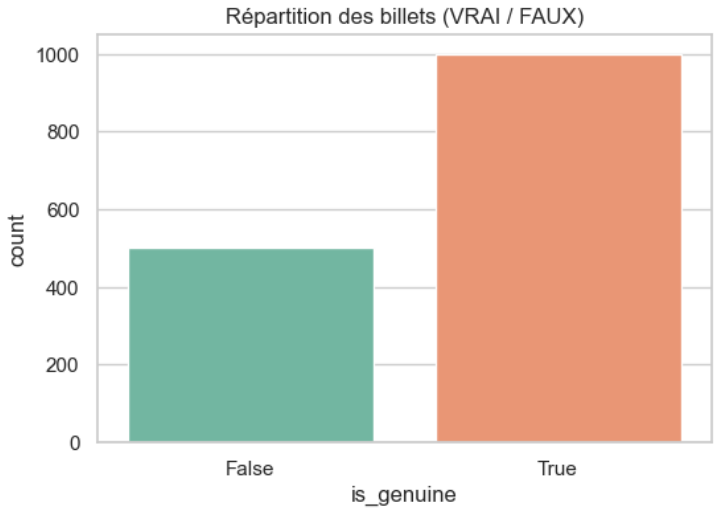

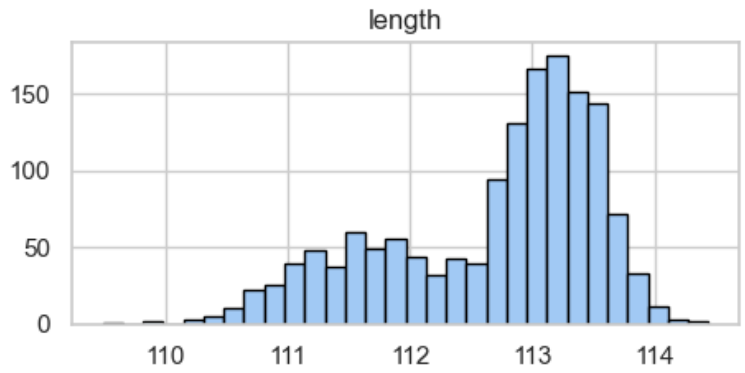

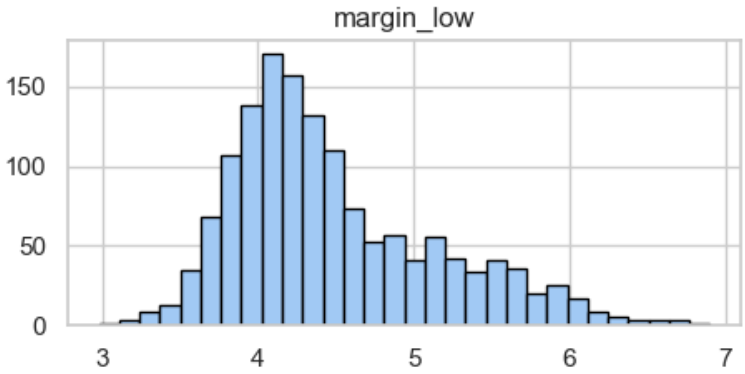

- Répartition : **1000 vrais vs 500 faux** (≈ 67 % / 33 %)
- Analyse des distributions :
  - *length* et *diagonal* plus dispersées ⟶ discriminantes
  - *height_left* et *height_right* très corrélées
  - marges = variabilité intéressante
- Observation : **signaux clairs pour différencier vrais/faux**

Exploration initiale 2/2

- Tests de Student → **p-values < 0.001** pour toutes les variables
- Variables les plus discriminantes :
  - **length** (plus grande chez les vrais)
  - **margin_low / margin_up** (plus petites chez les vrais)
- Conclusion : **toutes les variables sont utiles** pour la modélisation

Variable	Différence observée (vrais vs faux)	Discriminante ?
length	plus grande chez les vrais	très forte
diagonal	légèrement plus grande chez les vrais	significative
height_left	plus petite chez les vrais	forte
height_right	plus petite chez les vrais	forte
margin_low	plus petite chez les vrais	très forte
margin_up	plus petite chez les vrais	très forte

Algorithmes testés - Régression logistique

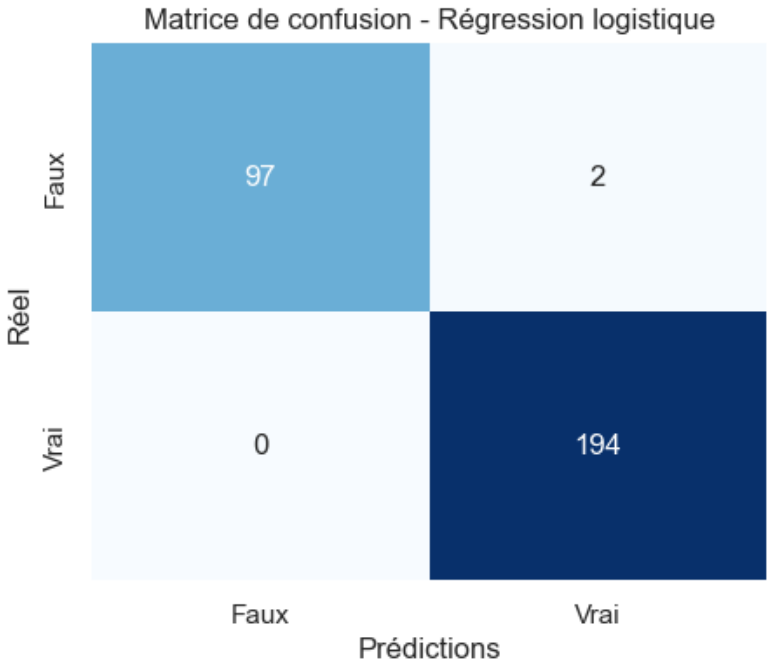

- Modèle supervisé linéaire
- Accuracy : **99,32 %**
- Très bon équilibre précision / rappel
- AUC : **0.9997 (quasi parfait)**
- 2 erreurs sur 293 billets

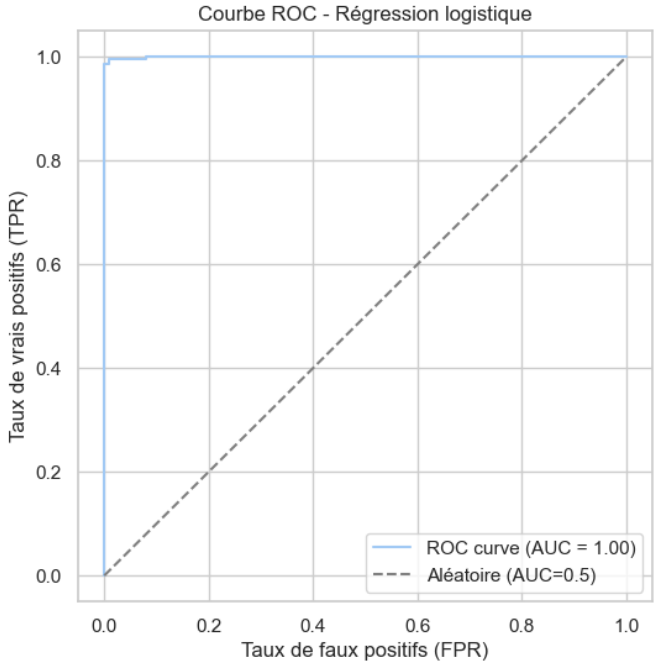

Algorithmes testés - K-means (non supervisé, classification via centroïdes)

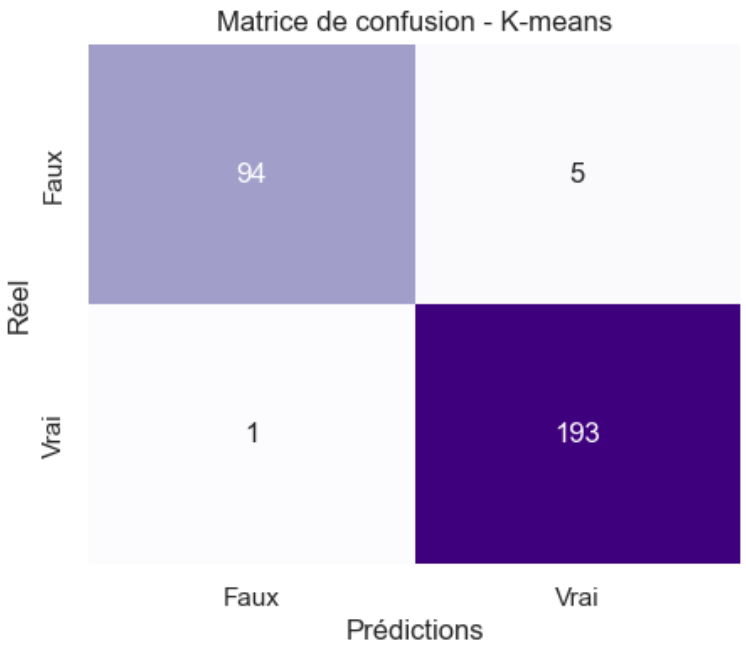

- Modèle non supervisé → 2 clusters (vrais/faux)
- Accuracy : **97,95 %**
- 5 faux positifs + 1 faux négatifs
- Séparation nette et cohérente (longueur ↑, marges ↓ pour vrais)

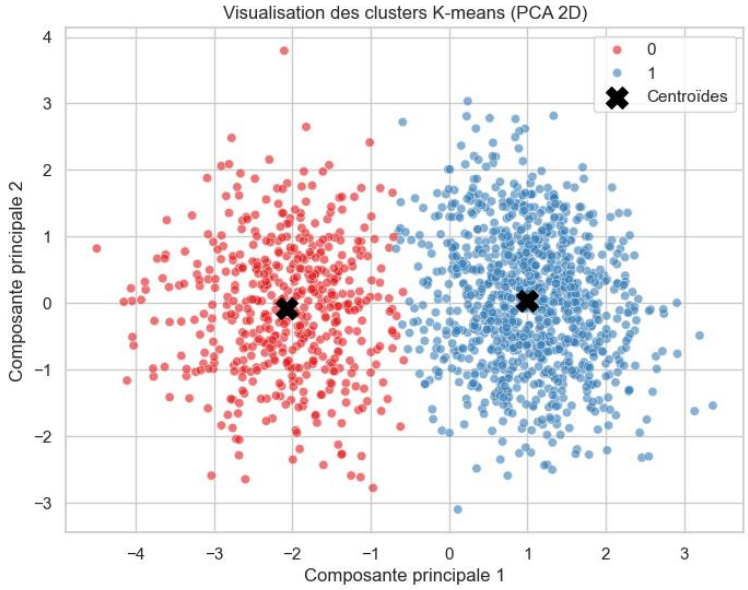

Algorithmes testés - KNN

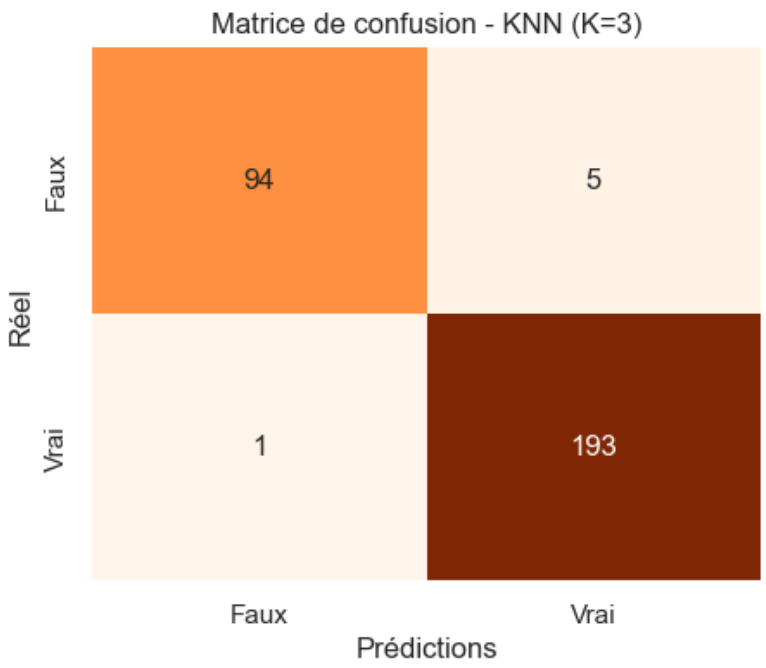

- Méthode des k plus proches voisins
- K optimal = **3** (cross-validation)
- Accuracy : **97,95 %** (meilleur modèle)
- Très faible nombre d'erreurs (6 / 293)
- Robuste et stable autour de K=3

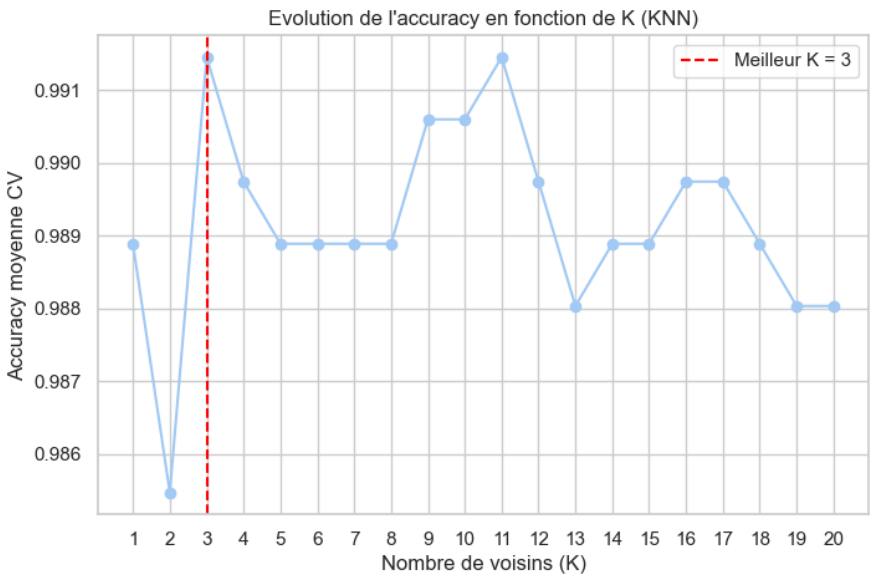

Algorithmes testés - Random Forest

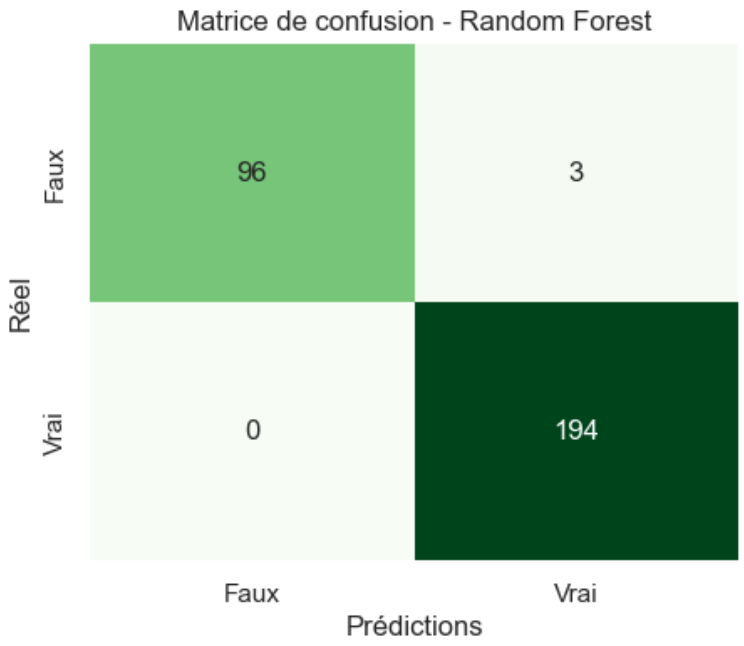

- Ensemble d'arbres de décision
- Accuracy : **98,98 %**
- 3 erreurs (0 FN, 3 FP)
- Importance des variables :
  - length + margin_low → ~80 %
  - marges et hauteurs secondaires

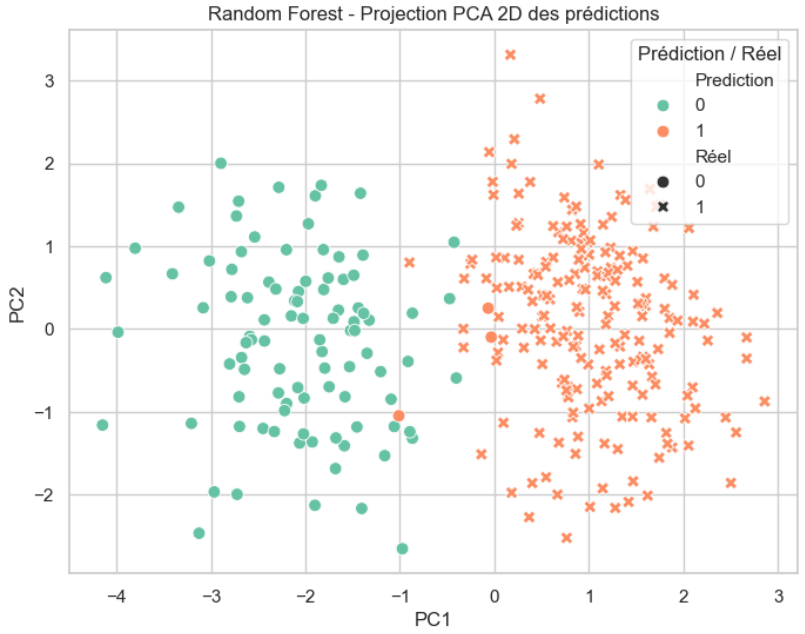

Résultats comparatifs

Modèle	Accuracy	Précision	Rappel	F1-score	Particularités
Régression logistique	99,32%	0,99	1	0,99	Simple, interprétable, excellentes performances
K-means (non supervisé)	97,95%	0,97	0,99	0,98	Bon résultat malgré non supervision, nécessite mapping
KNN (K=3)	97,95%	0,97	0,99	0,98	Performant, robuste mais sensible au choix de K
Random Forest	98,98%	0,98	1	0,99	Robuste, capable de capturer relations non linéaires

Choix du modèle final

Modèle retenu : **Régression logistique**

Pourquoi ?

- Légère supériorité en performance (Accuracy 99,3 % ; F1 = 0,99)
- Méthode simple et intuitive
- Bien adapté aux données géométriques normalisées
- Excellente robustesse et très peu de faux négatifs

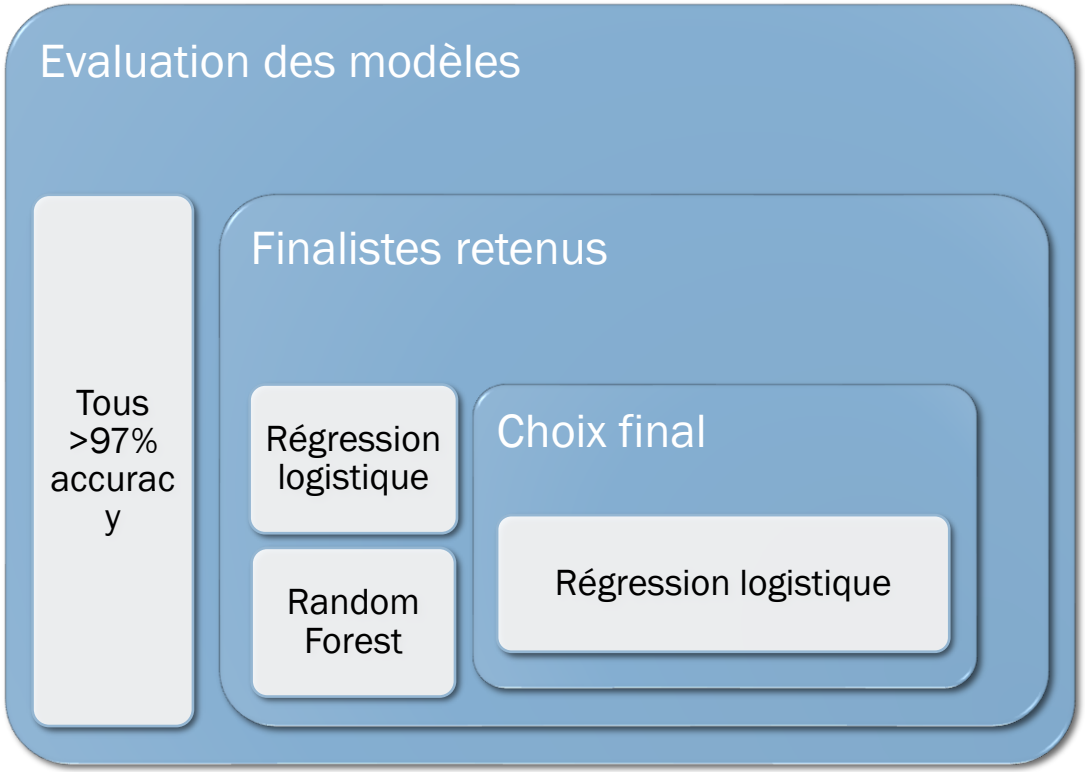

Application fonctionnelle

- Notebook dédié = outil opérationnel
- Entrée : fichier externe (billets_production.csv)
- Étapes : prétraitement → prédiction → sortie CSV
- Résultat : prédictions prêtes à l'emploi

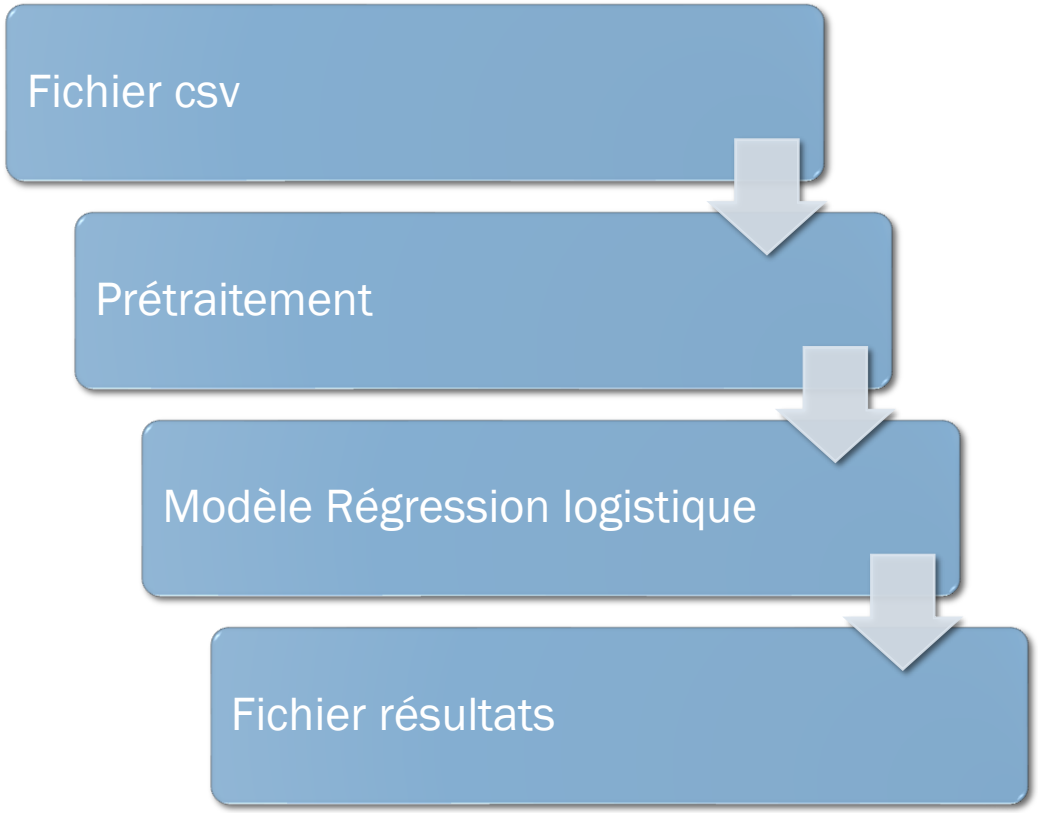

Exemple de résultats

	diagonal	height_left	height_right	margin_low	margin_up	length	id	prediction
0	171.76	104.01	103.54	5.21	3.30	111.42	A_1	0
1	171.87	104.17	104.13	6.00	3.31	112.09	A_2	0
2	172.00	104.58	104.29	4.99	3.39	111.57	A_3	0
3	172.49	104.55	104.34	4.44	3.03	113.20	A_4	1
4	171.65	103.63	103.56	3.77	3.16	113.33	A_5	1

- Exemple pratique : 5 billets testés
- Colonnes initiales + colonne *prediction*
- Résultat immédiat sur chaque billet

0 = billet faux, 1 = billet vrai (en accord avec le codage utilisé pour la régression logistique).

Conclusion & Perspectives

- Modèle retenu : **Régression logistique**, fiable et performant
- Application fonctionnelle opérationnelle
- Limite : uniquement mesures géométriques
- Ouverture : intégrer texture, encre, spectroscopie…

Merci pour votre attention