Projet n°3

Présentation de méthodologie

26 novembre 2024

Marie HENAULT

Introduction : Contexte et Objectifs

- **Contexte :**
  - Formation – Projet n°3 : Analyse des données pour une entreprise d'assurance habitation.
  - Objectif : utiliser SQL pour optimiser la prise de décision business.

- **Objectifs pédagogiques :**
  - Concevoir un schéma relationnel.
  - Créer et charger une base de données.
  - Rédiger des requêtes SQL simples et efficaces.

- **Étapes clés du projet :**
  1. Familiarisation avec les types de données.
  2. Conception d’un schéma relationnel.
  3. Création et chargement de la base.
  4-5. Rédaction et optimisation des requêtes SQL.
  6. Présentation de la méthodologie et des résultats.

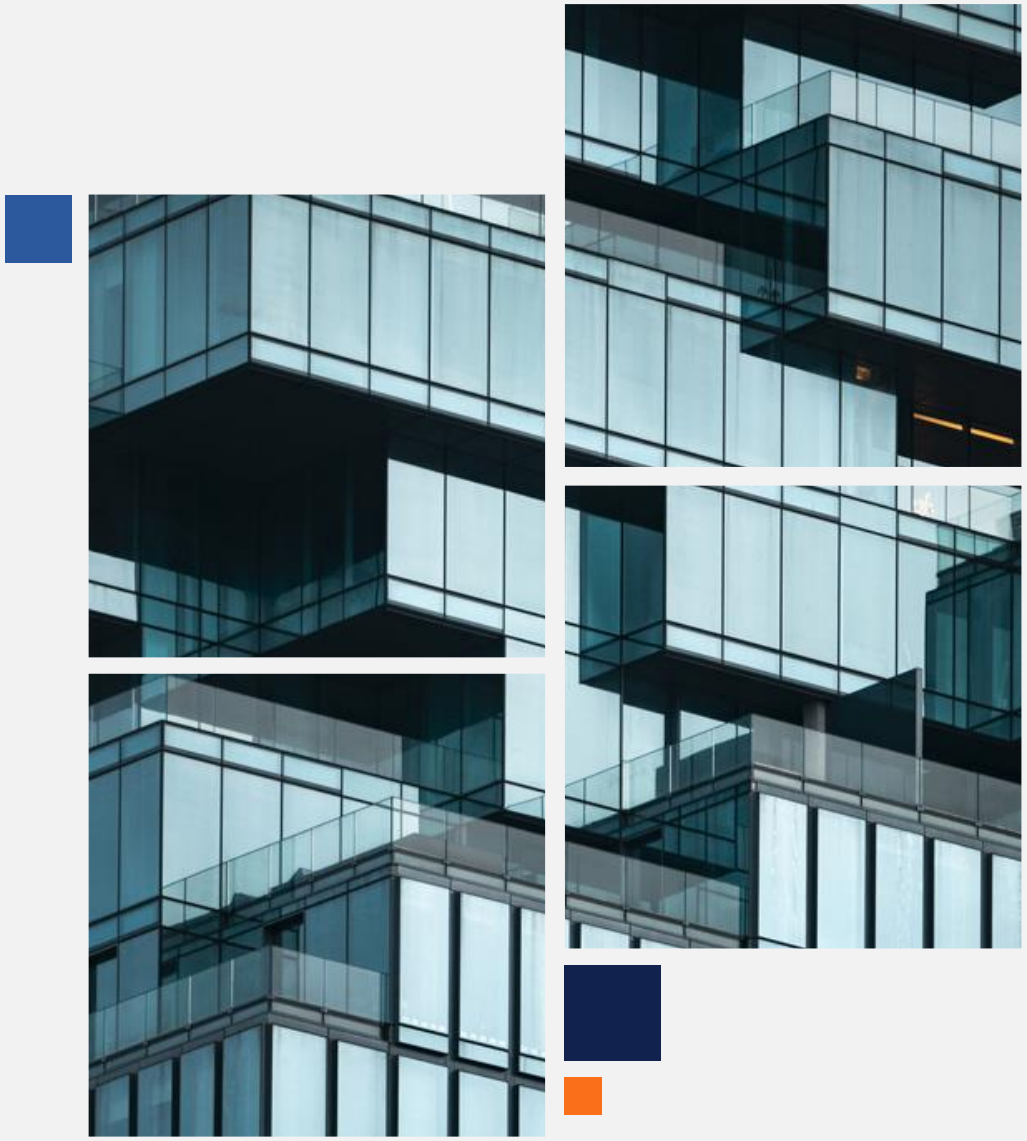

Dictionnaire des données : Analyse et structure

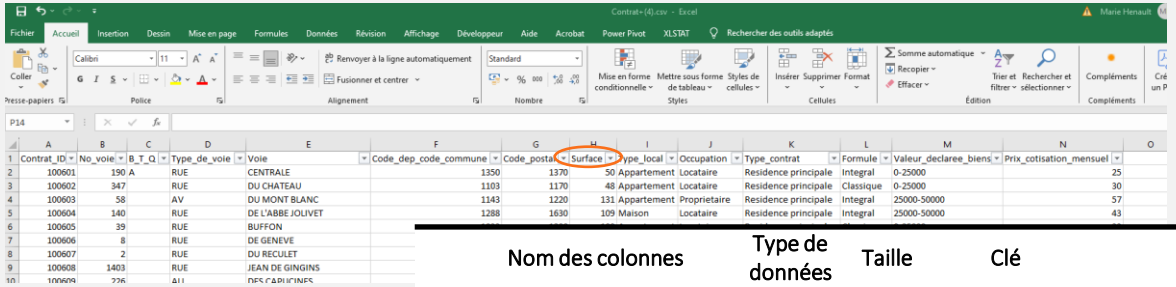

Contrat_ID	No_voie	B_T_Q	Type_de_voie	Voie	Code_dep_code_commune	Code_postal	Surface	Type_local	Occupation	Type_contrat	Formule	Valeur_declaree_biens	Prix_cotisation_mensuel
100601	190	A	RUE	CENTRALE	1350	1370	50	Appartement	Locataire	Residence principale	Integral	0-25000	25
100602	347		RUE	DU CHATEAU	1103	1170	48	Appartement	Locataire	Residence principale	Classique	0-25000	30
100603	58		AV	DU MONT BLANC	1143	1220	131	Appartement	Proprietaire	Residence principale	Integral	25000-50000	57
100604	140		RUE	DE L'ABBE JOLIVET	1288	1630	109	Maison	Locataire	Residence principale	Integral	25000-50000	43
100605	39		RUE	BUFFON									
100606	8		RUE	DE GENEVE									
100607	2		RUE	DU RECULET									
100608	1403		RUE	JEAN DE GINGINS									

Contrat.csv

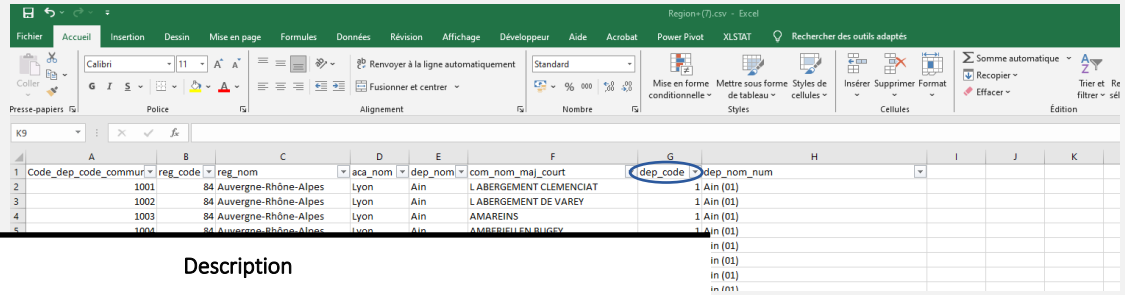

Code_dep_code_commur	reg_code	reg_nom	aca_nom	dep_nom	com_nom_maj_court	dep_code	dep_nom_num
1001	84	Auvergne-Rhône-Alpes	Lyon	Ain	L ABERGEMENT CLEMENCIAT	1	Ain (01)
1002	84	Auvergne-Rhône-Alpes	Lyon	Ain	L ABERGEMENT DE VAREY	1	Ain (01)
1003	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMAREINS	1	Ain (01)
1004	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBERIEU EN BUGEY	1	Ain (01)

Region.csv

	Nom des colonnes	Type de données	Taille	Clé	Description
CONTRAT.CSV	Contrat_ID	INT		Clé primaire	Id unique pour les contrats
	No_voie	INT			Numéro dans la voie pour l'adresse du logement assuré
	B_T_Q	CHAR	1		Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
	Type_de_voie	CVARCHAR	4		Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
	Voie	TEXT	-		Libellé de la voie pour l'adresse du logement assuré
	Code_dep_code_commune	CVARCHAR	6	Clé secondaire	Concaténation du code département et code commune pour avoir une clé unique
	Code_postal	VARCHAR	5		Code postal pour l'adresse du logement assuré
	Surface	INT	-		Surface en m² du logement
	Type_local	VARCHAR	25		Type de logement, par exemple "maison", "appartement"
	Occupation	VARCHAR	25		Statut d'occupation du logement, comme "locataire" ou "propriétaire"
	Type_contrat	VARCHAR	25		Type de contrat, tel que "résidence principale", "résidence secondaire", ou "mise en location"
	Formule	VARCHAR	10		Type de formule choisie, par exemple "classique" ou "intégrale"
	Valeur_declaree_biens	VARCHAR	10		Valeur déclarée des biens assurés
	Prix_cotisation_mensuel	INT	-		Montant de la cotisation mensuelle
REGION.CSV	Code_dep_code_commune	CVARCHAR	6	Clé primaire	Concaténation du code département et code commune pour avoir une clé unique
	reg_code	INT	-		Code numérique de la région
	reg_nom	TEXT	-		Nom de la région
	aca_nom	TEXT	-		Ville principale de la région académique
	dep_nom	TEXT	-		Nom complet du département
	com_nom_maj_court	TEXT	-		Nom de la commune
	dep_code	VARCHAR	3		Code numérique du département
	dep_nom_num	TEXT	-		Nom complet du département suivi de son code

Identification des types de données

Ex: Surface
=> nombre entier
=>type INT

Identification des tailles des champs

Ex: dep_code
=> Nombre max chiffre dep = 3
=> 3

Schéma relationnel : Méthodologie et construction

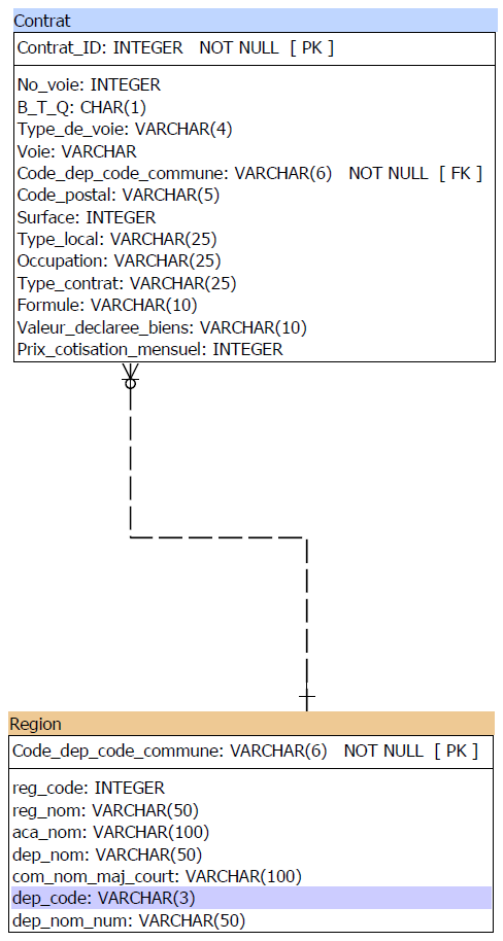


```
CREATE TABLE Region (
        Code_dep_code_commune VARCHAR(6) NOT NULL,
        reg_code INTEGER,
        reg_nom VARCHAR(50),
        aca_nom VARCHAR(100),
        dep_nom VARCHAR(50),
        com_nom_maj_court VARCHAR(100),
        dep_code VARCHAR(3),
        dep_nom_num VARCHAR(50),
        CONSTRAINT Code_dep_code_commune PRIMARY KEY (Code_dep_code_commune)
);

CREATE TABLE Contrat (
        Contrat_ID INTEGER NOT NULL,
        No_voie INTEGER,
        B_T_Q CHAR(1),
        Type_de_voie VARCHAR(4),
        Voie VARCHAR,
        Code_dep_code_commune VARCHAR(6) NOT NULL,
        Code_postal VARCHAR(5),
        Surface INTEGER,
        Type_local VARCHAR(25),
        Occupation VARCHAR(25),
        Type_contrat VARCHAR(25),
        Formule VARCHAR(10),
        Valeur_declaree_biens VARCHAR(10),
        Prix_cotisation_mensuel INTEGER,
        CONSTRAINT Contrat_ID PRIMARY KEY (Contrat_ID)
);

 ALTER TABLE Contrat ADD CONSTRAINT Region_Contrat_fk
FOREIGN KEY (Code_dep_code_commune)
REFERENCES Region (Code_dep_code_commune)
ON DELETE NO ACTION
ON UPDATE NO ACTION
NOT DEFERRABLE;
```

Étape 1 : Analyse de l'ébauche fournie

Étape 2 : Modification des types de données et des contraintes

Étape 3 : Ajout des colonnes manquantes

Étape 4 : Vérification des relations et génération du schéma

Étape 5 : Aperçu visuel

Création de la base de données

Nettoyage des données et préparation des fichiers

Création des tables via le script SQL généré

Importation des données avec vérification des lignes

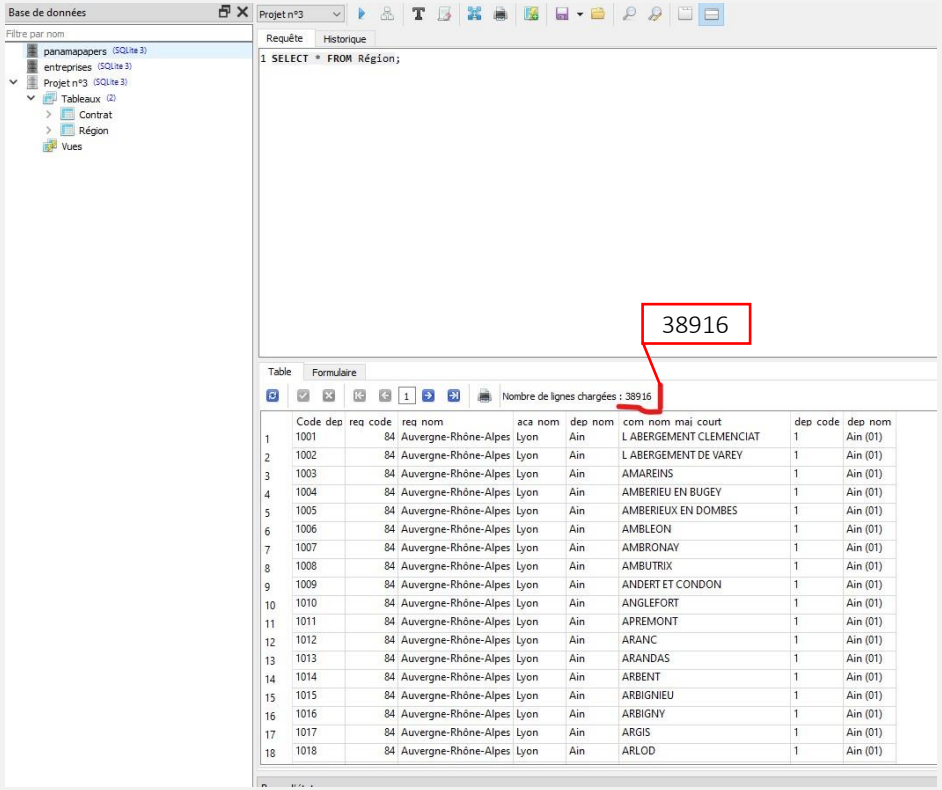

	Code dep	reg code	reg nom	aca nom	dep nom	com nom maj court	dep code	dep nom
1	1001	84	Auvergne-Rhône-Alpes	Lyon	Ain	L ABERGEMENT CLEMENCIAT	1	Ain (01)
2	1002	84	Auvergne-Rhône-Alpes	Lyon	Ain	L ABERGEMENT DE VAREY	1	Ain (01)
3	1003	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMAREINS	1	Ain (01)
4	1004	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBERIEU EN BUGEY	1	Ain (01)
5	1005	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBERIEUX EN DOMBES	1	Ain (01)
6	1006	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBLEON	1	Ain (01)
7	1007	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBRONAY	1	Ain (01)
8	1008	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBUTRIX	1	Ain (01)
9	1009	84	Auvergne-Rhône-Alpes	Lyon	Ain	ANDERT ET CONDON	1	Ain (01)
10	1010	84	Auvergne-Rhône-Alpes	Lyon	Ain	ANGLEFORT	1	Ain (01)
11	1011	84	Auvergne-Rhône-Alpes	Lyon	Ain	APREMONT	1	Ain (01)
12	1012	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARANC	1	Ain (01)
13	1013	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARANDAS	1	Ain (01)
14	1014	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARBENT	1	Ain (01)
15	1015	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARBIGNIEU	1	Ain (01)
16	1016	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARBIGNY	1	Ain (01)
17	1017	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARGIS	1	Ain (01)
18	1018	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARLOD	1	Ain (01)

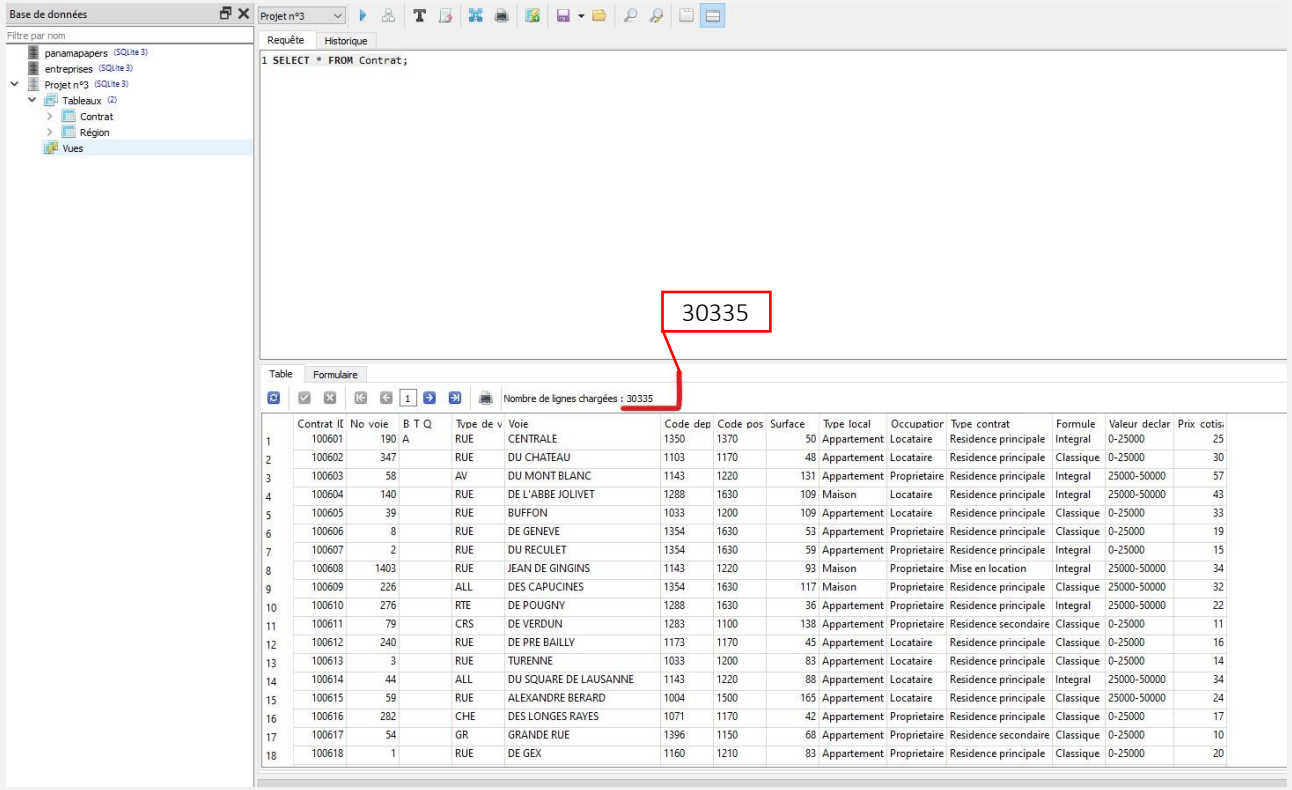

	Contrat II	No voie	B T Q	Type de v	Voie	Code dep	Code pos	Surface	Type local	Occupatior	Type contrat	Formule	Valeur declar	Prix cotis
1	100601	190	A	RUE	CENTRALE	1350	1370	50	Appartement	Locataire	Residence principale	Integral	0-25000	25
2	100602	347		RUE	DU CHATEAU	1103	1170	48	Appartement	Locataire	Residence principale	Classique	0-25000	30
3	100603	58		AV	DU MONT BLANC	1143	1220	131	Appartement	Proprietaire	Residence principale	Integral	25000-50000	57
4	100604	140		RUE	DE L'ABBE JOLIVET	1288	1630	109	Maison	Locataire	Residence principale	Integral	25000-50000	43
5	100605	39		RUE	BUFFON	1033	1200	109	Appartement	Locataire	Residence principale	Classique	0-25000	33
6	100606	8		RUE	DE GENEVE	1354	1630	53	Appartement	Proprietaire	Residence principale	Classique	0-25000	19
7	100607	2		RUE	DU RECULET	1354	1630	59	Appartement	Proprietaire	Residence principale	Integral	0-25000	15
8	100608	1403		RUE	JEAN DE GINGINS	1143	1220	93	Maison	Proprietaire	Mise en location	Integral	25000-50000	34
9	100609	226		ALL	DES CAPUCINES	1354	1630	117	Maison	Proprietaire	Residence principale	Classique	25000-50000	32
10	100610	276		RTE	DE POUGNY	1288	1630	36	Appartement	Proprietaire	Residence principale	Integral	25000-50000	22
11	100611	79		CRS	DE VERDUN	1283	1100	138	Appartement	Proprietaire	Residence secondaire	Classique	0-25000	11
12	100612	240		RUE	DE PRE BAILLY	1173	1170	45	Appartement	Locataire	Residence principale	Classique	0-25000	16
13	100613	3		RUE	TURENNE	1033	1200	83	Appartement	Locataire	Residence principale	Classique	0-25000	14
14	100614	44		ALL	DU SQUARE DE LAUSANNE	1143	1220	88	Appartement	Locataire	Residence principale	Integral	25000-50000	34
15	100615	59		RUE	ALEXANDRE BERARD	1004	1500	165	Appartement	Locataire	Residence principale	Classique	25000-50000	24
16	100616	282		CHE	DES LONGES RAYES	1071	1170	42	Appartement	Proprietaire	Residence principale	Classique	0-25000	17
17	100617	54		GR	GRANDE RUE	1396	1150	68	Appartement	Proprietaire	Residence secondaire	Classique	0-25000	10
18	100618	1		RUE	DE GEX	1160	1210	83	Appartement	Proprietaire	Residence principale	Classique	0-25000	20

Requêtes SQL 1 à 3 : Analyse des données

Requête 1 : Lister les numéros de contrats (contrat_ID) avec leur surface pour la commune de Caen.

```
SELECT c.Contrat_ID, c.Surface
FROM Contrat c
JOIN Région r ON c.Code_dep_code_commune =
r.Code_dep_code_commune
WHERE r.com_nom_maj_court = 'CAEN';
```

Table | Formulaire

Nombre de lignes chargées : 4

	Contrat_ID	Surface
1	103791	35
2	103792	99
3	103793	40
4	103794	20

Requête 2 : Lister les numéros de contrats avec le type de contrat et leur formule pour les maisons du département 71.

```
SELECT c.Contrat_ID, c.Type_contrat, c.Formule
FROM Contrat c
JOIN Région r
ON c.Code_dep_code_commune =
r.Code_dep_code_commune
WHERE c.Type_local = 'Maison'
AND r.dep_code = '71';
```

Table | Formulaire

Nombre de lignes chargées : 4

	Contrat_ID	Type_contrat	Formule
1	114768	Residence principale	Integral
2	114779	Residence principale	Classique
3	114782	Residence principale	Classique
4	114812	Residence principale	Integral

Requête 3 : Lister le nom des régions de France.

```
SELECT DISTINCT reg_nom
FROM Région;
```

Table | Formulaire

Nombre de lignes chargées : 19

	reg_nom
1	Auvergne-Rhône-Alpes
2	Hauts-de-France
3	Provence-Alpes-Côte d'Azur
4	Grand Est
5	Occitanie
6	Normandie
7	Nouvelle-Aquitaine
8	Centre-Val de Loire
9	Bourgogne-Franche-Comté
10	Bretagne
11	Pays de la Loire
12	Ile-de-France
13	Guadeloupe
14	Martinique
15	Guyane
16	La Réunion
17	Collectivités d'outre-mer
18	Mayotte
19	Corse

Requêtes SQL 4 à 6 : Analyse des données

Requête 4 : Quels sont les 5 contrats qui ont les surfaces les plus élevées ?

```
SELECT Contrat_ID, Surface
FROM Contrat
ORDER BY Surface DESC
LIMIT 5;
```

Table | Formulaire

Nombre de lignes chargées : 5

	Contrat_ID	Surface
1	104211	815
2	105463	742
3	130878	595
4	100822	570
5	109872	559

Requête 5 : Quel est le prix moyen de la cotisation mensuelle ?

```
SELECT AVG(Prix_cotisation_mensuel) AS
Prix_moyen
FROM Contrat;
```

Table | Formulaire

Nombre de lignes chargées : 1

	Prix_moyen
1	19.32869622548212

Requête 6 : Quel est le nombre de contrats pour chaque catégorie de prix de la valeur déclarée des biens ?

```
SELECT
Valeur_declaree_biens AS Catégorie_prix,
COUNT(*) AS Nombre_de_contrats
FROM Contrat
GROUP BY Valeur_declaree_biens;
```

Table | Formulaire

Nombre de lignes chargées : 4

	Catégorie_prix	Nombre_de_contrats
1	0-25000	22720
2	100000+	104
3	25000-50000	6815
4	50000-100000	696

Requêtes SQL 7 à 9 : Analyse des données

Requête 7 : Quel est le nombre de formules “integral” sur la région Pays de la Loire ?

```
SELECT COUNT(*) AS
Nombre_de_formules_integrales
FROM Contrat c
JOIN Région r ON c.Code_dep_code_commune =
r.Code_dep_code_commune
WHERE c.Formule = 'Integral'
AND r.reg_nom = 'Pays de la Loire'
```

Table | Formulaire

Nombre de lignes chargées : 1

	Nombre de formules integrales
1	589

Requête 8 : Lister les numéros de contrats avec le type de contrat et leur formule pour les maisons du département 71.

```
SELECT c.Contrat_ID, c.Type_contrat, c.Formule
FROM Contrat c
JOIN Région r ON c.Code_dep_code_commune =
r.Code_dep_code_commune
WHERE c.Type_local = 'Maison'
AND r.dep_code = '71';
```

Table | Formulaire

Nombre de lignes chargées : 4

	Contrat ID	Type contrat	Formule
1	114768	Residence principale	Integral
2	114779	Residence principale	Classique
3	114782	Residence principale	Classique
4	114812	Residence principale	Integral

Requête 9 : Quelle est la surface moyenne des contrats à Paris ?

```
SELECT AVG(c.Surface) AS Surface_moyenne
FROM Contrat c
JOIN Région r ON c.Code_dep_code_commune =
r.Code_dep_code_commune
WHERE r.dep_code = '75';
```

Table | Formulaire

Nombre de lignes chargées : 1

	Surface moyenne
1	51.7695498859157 9

Requêtes SQL 10 à 12 : Analyse des données

Requête 10 : Classement des 10 départements où le prix moyen de la cotisation est le plus élevé.

```
SELECT r.dep_code,
ROUND(AVG(c.Prix_cotisation_mensuel), 2) AS
Prix_moyen_cotisation
FROM Contrat c
JOIN Région r ON c.Code_dep_code_commune =
r.Code_dep_code_commune
GROUP BY r.dep_code
ORDER BY Prix_moyen_cotisation DESC
LIMIT 10;
```

Table | Formulaire

Nombre de lignes chargées : 10

	dep_code	Prix_moyen_cotisation
1	75	36.4
2	92	26.27
3	94	19.82
4	78	18.89
5	69	18.49
6	1	18.24
7	6	18.14
8	17	17.32
9	74	17.15
10	2A	17.07

Requête 11 : Liste des communes ayant eu au moins 150 contrats.

```
SELECT r.com_nom_maj_court AS Commune,
COUNT(c.Contrat_ID) AS Nombre_de_contrats
FROM Contrat c
JOIN Région r ON c.Code_dep_code_commune =
r.Code_dep_code_commune
GROUP BY r.com_nom_maj_court
HAVING COUNT(c.Contrat_ID) >= 150
ORDER BY Nombre_de_contrats DESC;
```

Table | Formulaire

Nombre de lignes chargées : 20

	Commune	Nombre de contrats
1	PARIS 18	515
2	PARIS 17	468
3	PARIS 15	407
4	PARIS 16	394
5	NICE	387
6	PARIS 11	381
7	PARIS 20	302
8	BORDEAUX	302
9	NANTES	291
10	PARIS 19	266
11	PARIS 10	263
12	PARIS 12	252
13	PARIS 14	222
14	GRENOBLE	220
15	PARIS 9	204
16	TOULOUSE	187
17	TOULON	170
18	COURBEVOIE	163
19	LILLE	161
20	PARIS 3	159

Requête 12 : Quel est le nombre de contrats pour chaque région ?

```
SELECT r.reg_nom AS Region, COUNT(c.Contrat_ID)
AS Nombre_de_contrats
FROM Contrat c
JOIN Région r ON c.Code_dep_code_commune =
r.Code_dep_code_commune
GROUP BY r.reg_nom;
```

Table | Formulaire

Nombre de lignes chargées : 16

	Region	Nombre de contrats
1	Auvergne-Rhône-Alpes	3042
2	Bourgogne-Franche-Comté	293
3	Bretagne	947
4	Centre-Val de Loire	598
5	Corse	247
6	Grand Est	769
7	Guyane	37
8	Hauts-de-France	1189
9	Ile-de-France	14177
10	La Réunion	8
11	Martinique	73
12	Normandie	824
13	Nouvelle-Aquitaine	2038
14	Occitanie	1609
15	Pays de la Loire	1196
16	Provence-Alpes-Côte d'Azur	3279

Conclusion

- Ce que j’ai réalisé :
  - Analyse des données et modélisation d’un schéma relationnel.
  - Construction d’une base de données fonctionnelle.
  - Rédaction de requêtes SQL répondant à des problématiques précises.
- Ce que j’ai appris :
  - Structurer, interroger et analyser des données complexes.

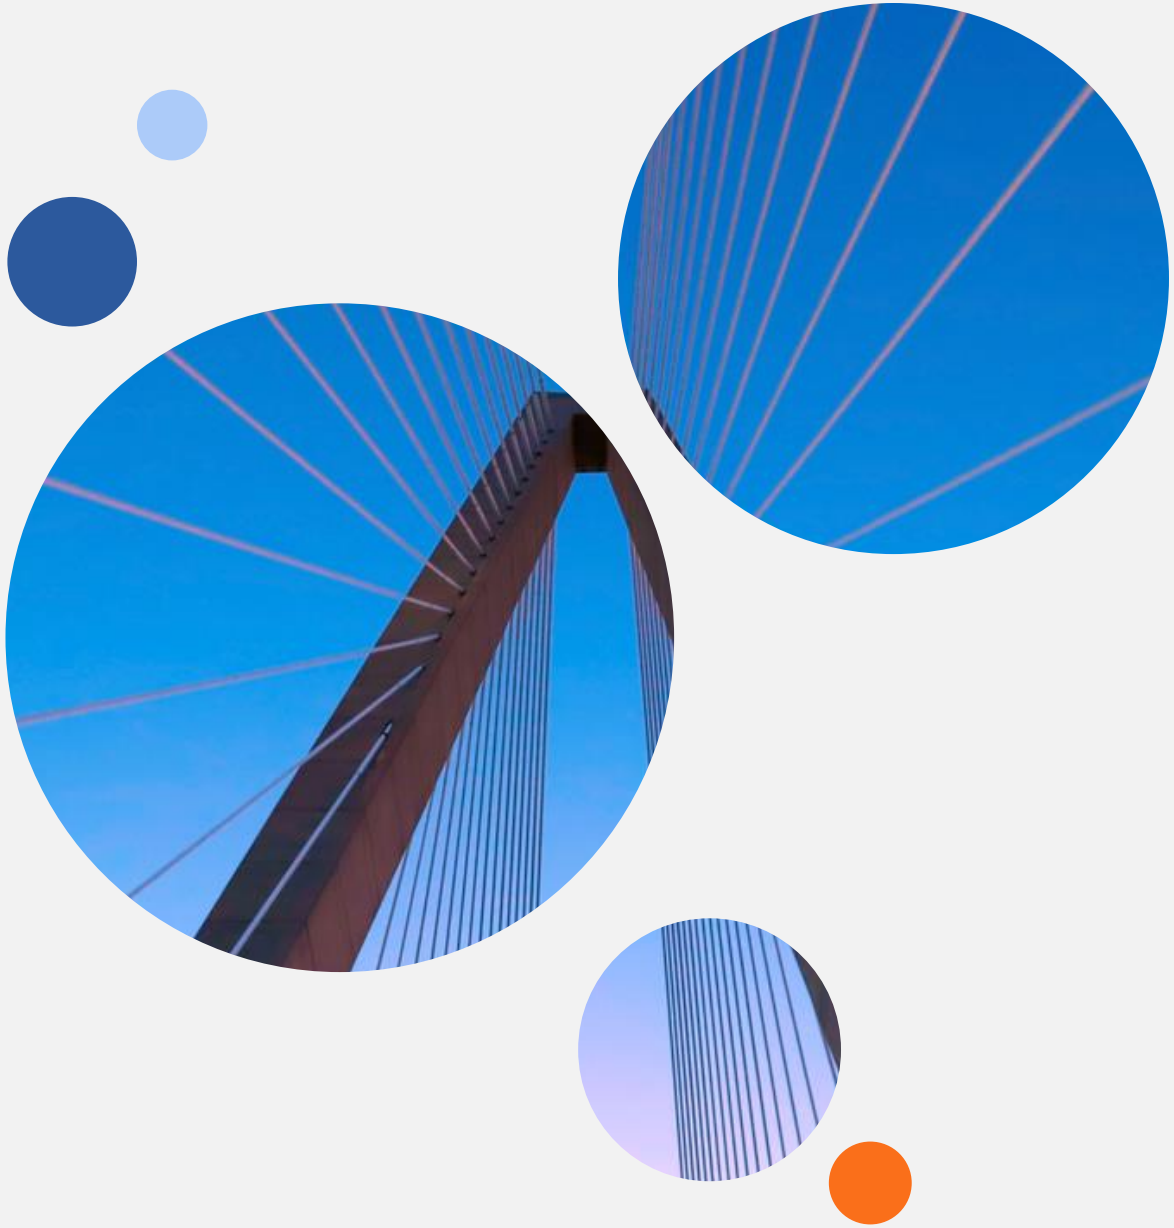

Je vous remercie pour votre attention

Marie HENAULT